Institución Universitaria ITM

Departamento de Sistemas • Ingeniería de Sistemas

Curso: Análisis de Datos • Semestre 2026-1

Docente: Daniel Alexis Nieto Mora

Proyecto Integral de Business Intelligence

Dataset: Transporte Uber - Nueva York (2009–2015)

Equipo 4 — Transporte (Uber)

Integrante 1: Juan David Palacio Calderón

Integrante 2: Sebastián Cuencar Cardona

Integrante 3: Julián Andrés Ramírez Bedoya

Integrante 4: Juan José Rua David

Índice

1. Fase 1: Comprensión del Problema **2**
1.1. Descripción del contexto del dataset 2
1.1.1. Usuarios del análisis 2
1.1.2. Propósito del análisis 3
1.2. Identificación del problema central de análisis 3
1.3. Preguntas clave de análisis 3

2. Fase 2: Formulación de Hipótesis **5**
2.1. Hipótesis 1: Distancia recorrida como predictor de la tarifa 5
2.1.1. Planteamiento 5
2.1.2. Justificación para el negocio 5
2.1.3. Variables involucradas 5
2.1.4. Prueba estadística propuesta 5
2.2. Hipótesis 2: Efecto de la franja horaria sobre la tarifa promedio 6
2.2.1. Planteamiento 6
2.2.2. Definición de los grupos horarios 6
2.2.3. Justificación para el negocio 7
2.2.4. Variables involucradas 7
2.2.5. Prueba estadística propuesta 7
2.3. Hipótesis 3: Crecimiento del volumen de viajes entre 2009 y 2015 8
2.3.1. Planteamiento 8
2.3.2. Justificación para el negocio 8
2.3.3. Variables involucradas 8
2.3.4. Prueba estadística propuesta 8
2.4. Resumen de hipótesis estadísticas 9

1. Fase 1: Comprensión del Problema

1.1. Descripción del contexto del dataset

El dataset utilizado en este proyecto corresponde a registros históricos de viajes realizados a través de la plataforma **Uber** en la ciudad de **Nueva York** durante el período comprendido entre **2009 y 2015**. Uber es una empresa de transporte bajo demanda que conecta pasajeros con conductores particulares mediante una aplicación móvil, operando bajo el modelo de economía colaborativa (*ridesharing*).

Cada registro del conjunto de datos representa un viaje individual e incluye información sobre la fecha y hora de recogida, las coordenadas geográficas del punto de origen y destino, el número de pasajeros transportados y el valor de la tarifa cobrada. Este tipo de dato transaccional posee alto valor estratégico para el análisis de la demanda, el comportamiento del consumidor y la optimización de precios en una plataforma de movilidad urbana.

Cuadro 1. Descripción de las variables del dataset

Variable	Tipo de dato	Descripción
`key`	Texto	Identificador único del viaje
`fare_amount`	Numérico	Tarifa cobrada al pasajero (USD)
`pickup_datetime`	Fecha/Hora	Fecha y hora de recogida en formato UTC
`pickup_longitude`	Numérico	Longitud geográfica del punto de recogida
`pickup_latitude`	Numérico	Latitud geográfica del punto de recogida
`dropoff_longitude`	Numérico	Longitud geográfica del punto de destino
`dropoff_latitude`	Numérico	Latitud geográfica del punto de destino
`passenger_count`	Numérico	Número de pasajeros por viaje

1.1.1. Usuarios del análisis

Los resultados de este proyecto son de utilidad para distintos actores dentro del ecosistema de Uber y de la movilidad urbana:

- **Gerencia de operaciones:** para identificar patrones de demanda y optimizar la disponibilidad de conductores según zonas y franjas horarias.
- **Equipo de fijación de precios (*pricing*):** para evaluar si las tarifas reflejan ade-

cuadamente variables operativas como la distancia recorrida, el horario y el nivel de demanda.

- **Analistas urbanos y reguladores de transporte:** para comprender el impacto del transporte privado por aplicación en la movilidad de Nueva York.

1.1.2. Propósito del análisis

El presente análisis busca transformar datos transaccionales en inteligencia de negocio accionable: identificar franjas horarias y zonas de alta demanda, evaluar la relación entre la distancia y la tarifa cobrada, detectar patrones estacionales y comprender la evolución del servicio a lo largo de los seis años que abarca el dataset.

1.2. Identificación del problema central de análisis

El problema central que orienta este proyecto se enuncia de la siguiente manera:

> *¿Qué factores —temporales, espaciales y operativos— influyen significativamente en el valor de la tarifa de un viaje de Uber en Nueva York, y cómo puede esta información orientar la optimización de la estrategia de precios y la eficiencia operacional de la plataforma?*

El problema abarca tres dimensiones de análisis complementarias, descritas en la Tabla 2.

Cuadro 2. Dimensiones del problema de análisis de negocio

Dimensión	Descripción
Optimización de precios	Evaluar si la tarifa cobrada refleja adecuadamente la distancia recorrida y el nivel de demanda en el momento del viaje.
Análisis de la demanda	Determinar cuándo y dónde se concentra el mayor volumen de viajes e identificar patrones de estacionalidad o picos horarios.
Eficiencia operacional	Analizar si los patrones de ocupación del vehículo y la tarifa por kilómetro reflejan un uso eficiente de la plataforma.

1.3. Preguntas clave de análisis

Las siguientes preguntas guían el diseño del dashboard y la formulación de las hipótesis estadísticas. Todas son respondibles con las variables disponibles en el dataset.

Pregunta 1. Relación entre tarifa y distancia. ¿Existe una correlación estadísticamente significativa entre la distancia recorrida en cada viaje y la tarifa cobrada (`fare_amount`)? ¿Es la tarifa por kilómetro consistente a lo largo del período 2009–2015?

Pregunta 2. Patrones de demanda temporal. ¿En qué horas del día, días de la semana y meses del año se registra el mayor volumen de viajes? ¿Es posible identificar patrones de estacionalidad en la demanda del servicio en la ciudad de Nueva York?

Pregunta 3. Comportamiento geográfico de la demanda. ¿Cuáles son las zonas con mayor densidad de viajes originados? ¿Existen diferencias significativas en las tarifas promedio según la zona geográfica de recogida del pasajero?

Pregunta 4. Evolución histórica del servicio. ¿Cómo evolucionó el volumen de viajes y el nivel promedio de tarifas entre 2009 y 2015? ¿El crecimiento de la base de usuarios impactó el precio promedio por viaje?

Pregunta 5. Efecto del número de pasajeros sobre la tarifa. ¿El número de pasajeros (`passenger_count`) tiene un efecto estadísticamente significativo sobre la tarifa cobrada, o Uber aplica una tarifa esencialmente independiente del nivel de ocupación del vehículo?

2. Fase 2: Formulación de Hipótesis

En esta fase se plantean tres hipótesis estadísticas derivadas del problema central y de las preguntas de análisis formuladas en la Fase 1. Para cada hipótesis se define la hipótesis nula (H_0) y la hipótesis alternativa (H_1), se justifica su relevancia para el negocio, se identifican las variables involucradas y se propone la prueba estadística más adecuada con su respectiva justificación metodológica.

2.1. Hipótesis 1: Distancia recorrida como predictor de la tarifa

2.1.1. Planteamiento

H_0:

$\mu_{\text{madrugada}} = \mu_{\text{mañana}} = \mu_{\text{tarde}} = \mu_{\text{noche}}$

La tarifa media es estadísticamente igual en todas las franjas horarias.

H_1: $\exists\ i, j\ :\ \mu_i \neq \mu_j$ — Al menos una franja horaria presenta una tarifa media significativamente diferente a las demás.

2.1.2. Justificación para el negocio

El modelo de tarificación de Uber incluye la distancia recorrida como uno de sus componentes fundamentales. Confirmar estadísticamente esta relación permite validar la coherencia del esquema de precios y detectar posibles anomalías: viajes cortos con tarifas elevadas, asociables al efecto del *surge pricing*, o viajes largos subvalorados que generen pérdidas para los conductores. Esta hipótesis constituye el fundamento cuantitativo del indicador clave de tarifa por kilómetro.

2.1.3. Variables involucradas

Cuadro 3. Variables de la Hipótesis 1

Variable	Rol estadístico	Origen en el dataset
`fare_amount`	Dependiente (continua)	Columna original del dataset
`distance_km`	Independiente (continua)	Calculada mediante la fórmula de Haversine

2.1.4. Prueba estadística propuesta

Se propone aplicar la **correlación de Pearson** como prueba principal, complementada con una **regresión lineal simple**.

- *Justificación:* Ambas variables son continuas y se espera una relación de tipo lineal entre ellas. El coeficiente de correlación de Pearson (r) cuantifica la fuerza y la dirección de dicha relación, y su prueba de significancia —basada en el estadístico t con $n-2$ grados de libertad— permite decidir sobre H_0.
- *Criterio de decisión:* Si $p < 0{,}05$ y $r > 0$, se rechaza H_0 en favor de H_1.
- *Complemento:* La regresión lineal estima el coeficiente β_1 (variación en la tarifa por cada kilómetro adicional) y el coeficiente de determinación R^2, que indica la proporción de variabilidad en la tarifa explicada por la distancia.

La ecuación del modelo de regresión propuesto es:

$$\widehat{\texttt{fare}}_i = \beta_0 + \beta_1 \cdot \texttt{distance_km}_i + \varepsilon_i \tag{1}$$

donde β_0 representa la tarifa base (intercepto) y β_1 es el incremento esperado en la tarifa por cada kilómetro adicional recorrido.

2.2. Hipótesis 2: Efecto de la franja horaria sobre la tarifa promedio

2.2.1. Planteamiento

H_0: $\mu_{\text{madrugada}} = \mu_{\text{mañana}} = \mu_{\text{tarde}} = \mu_{\text{noche}}$ — La tarifa media es estadísticamente igual en todas las franjas horarias.

H_1: $\exists\ i, j\ :\ \mu_i \neq \mu_j$ — Al menos una franja horaria presenta una tarifa media significativamente diferente a las demás.

2.2.2. Definición de los grupos horarios

Para este análisis, la variable `hour` (extraída de `pickup_datetime`) se categoriza en cuatro franjas horarias, tal como se describe en la Tabla 4.

Cuadro 4. Clasificación de viajes por franja horaria

Franja horaria	**Rango**	**Condición sobre `hour`**
Madrugada	00:00 – 05:59	$\texttt{hour} \in [0,\ 5]$
Mañana	06:00 – 11:59	$\texttt{hour} \in [6,\ 11]$
Tarde	12:00 – 17:59	$\texttt{hour} \in [12,\ 17]$
Noche	18:00 – 23:59	$\texttt{hour} \in [18,\ 23]$

2.2.3. Justificación para el negocio

El mecanismo de *surge pricing* de Uber se activa cuando la demanda de viajes supera la oferta de conductores disponibles, elevando las tarifas de forma dinámica. Si la hipótesis alternativa se confirma, existirá evidencia estadística de que la franja horaria es un determinante significativo del precio, lo que justifica implementar estrategias diferenciadas de disponibilidad de conductores, incentivos económicos en horas pico y comunicación proactiva de tarifas a los usuarios.

2.2.4. Variables involucradas

Cuadro 5. Variables de la Hipótesis 2

Variable	Rol estadístico	Origen en el dataset
`fare_amount`	Dependiente (continua)	Columna original del dataset
`time_of_day`	Independiente (factor, 4 niveles)	Derivada de `hour`
`hour`	Variable auxiliar de agrupación	Extraída de `pickup_datetime`

2.2.5. Prueba estadística propuesta

Se propone aplicar el **análisis de varianza de un factor (ANOVA de un factor)**.

- *Justificación:* El ANOVA de un factor es la prueba paramétrica estándar cuando se desea comparar las medias de una variable continua entre más de dos grupos independientes. En este caso, se compara la tarifa promedio entre las cuatro franjas horarias definidas.
- *Supuestos a verificar previamente:*
  1. Normalidad de los residuos por grupo: prueba de Shapiro-Wilk o Kolmogorov-Smirnov.
  2. Homogeneidad de varianzas entre grupos: prueba de Levene.
- *Criterio de decisión:* Si $p < 0{,}05$, se rechaza H_0 y se concluye que al menos una franja horaria presenta una tarifa media significativamente distinta a las demás.
- *Análisis post-hoc:* En caso de rechazar H_0, se aplica la **prueba de Tukey HSD** para identificar qué pares específicos de franjas horarias difieren entre sí.

El estadístico F del ANOVA se calcula como:

$$F = \frac{SCB \,/\, (k-1)}{SCW \,/\, (N-k)} \sim F_{k-1,\, N-k} \tag{2}$$

donde SCB es la suma de cuadrados entre grupos, SCW es la suma de cuadrados dentro de los grupos, $k = 4$ es el número de franjas horarias y N es el total de viajes en el dataset limpio.

2.3. Hipótesis 3: Crecimiento del volumen de viajes entre 2009 y 2015

2.3.1. Planteamiento

H_0: La distribución de viajes por año es uniforme a lo largo del período 2009–2015; no existen diferencias significativas entre los volúmenes anuales.

H_1: La distribución de viajes por año no es uniforme; el volumen de viajes creció de manera significativa entre 2009 y 2015.

2.3.2. Justificación para el negocio

Uber inició operaciones en Nueva York en 2011 y experimentó un crecimiento acelerado en los años siguientes. Por esta razón, los registros correspondientes a 2009 y 2010 son escasos o inexistentes en el dataset, lo que refuerza la hipótesis de una distribución no uniforme. Confirmar estadísticamente dicha expansión permite contextualizar la evolución de las tarifas: un mercado en crecimiento puede presentar mayor variabilidad de precios, mientras que un mercado maduro tiende hacia la estabilización tarifaria.

2.3.3. Variables involucradas

Cuadro 6. Variables de la Hipótesis 3

Variable	Rol estadístico	Origen en el dataset
`year`	Categórica (7 niveles)	Extraída de `pickup_datetime`
Frecuencia de viajes	Conteo observado por año	Agregación del dataset

2.3.4. Prueba estadística propuesta

Se propone aplicar la **prueba de bondad de ajuste Chi-cuadrado** (χ^2).

- *Justificación:* La variable `year` es categórica y se busca evaluar si la frecuencia observada de viajes en cada año difiere significativamente de la distribución esperada

bajo el supuesto de uniformidad. La prueba χ^2 de bondad de ajuste es la prueba no paramétrica estándar para este tipo de análisis de frecuencias.

- *Criterio de decisión:* Si $p < 0{,}05$, se rechaza H_0 y se concluye que el volumen de viajes no fue uniforme a lo largo del período analizado.

El estadístico de prueba se define como:

$$\chi^2 = \sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i} \sim \chi^2_{k-1} \tag{3}$$

donde O_i es la frecuencia observada de viajes en el año i, $E_i = N/k$ es la frecuencia esperada bajo el supuesto de uniformidad, $k = 7$ corresponde al número de años del período 2009–2015, y N es el total de viajes en el dataset limpio.

2.4. Resumen de hipótesis estadísticas

La Tabla 7 presenta una síntesis de las tres hipótesis planteadas.

Cuadro 7. Resumen de hipótesis estadísticas del proyecto

N.º	**Variable dependiente**	**Variable independiente**	**Prueba estadística**	**Nivel α**
1	`fare_amount`	`distance_km` (continua)	Pearson + Regresión lineal	0,05
2	`fare_amount`	`time_of_day` (4 grupos)	ANOVA + Tukey HSD	0,05
3	Frecuencia de viajes	`year` (7 niveles)	χ^2 bondad de ajuste	0,05